

# HW4 第四次作业解答

更新: 2025 年 12 月 2 日

## Exercise 1

因为依赖于 Legendre 多项式, 将  $[-1, 1]$  上  $w(x) = 1$  的 Gauss 求积法则称为 *Gauss-Legendre* 求积。10 点 Gauss-Legendre 法则的节点和权重在表 1 中给出。

表 1: 范围在  $[-1, 1]$  上 10 点 Gauss-Legendre 法则的节点和权重

$\pm x_i$	$A_i$
0.148874338981631	0.295524224714753
0.433395394129247	0.269266719309996
0.679409568299024	0.219086362515982
0.865063366688985	0.149451394150581
0.973906528517172	0.066671344308688

1. 画出权重-节点图。
2. 求出曲线  $y = x^2$  在  $[-1, 1]$  之间的面积 (分别使用 Gauss-Legendre 法、梯形法和 Simpson 法)。将它们与实际答案比较, 并评价该求积法的精确性。

解答 (1) 10 点 Gauss-Legendre 法则的节点和权重在表 1 中给出, 绘制权重-节点图 1 所示。




图 1: 10-point Gauss-Legendre quadrature nodes and weights

**解答 (2)** 实际答案为  $2/3 = 0.6666666667$ , 使用 Newton-Riemann, Newton-Trapezoidal, Newton-Simpson 和 Gaussian-Legendre 方法得到的结果如表 2 所示 (均是只计算了 10 个函数值)。

表 2: 各类数值积分方法比较

Method	Integration	Error
Actual	0.6666666667	-
Newton-Riemann	0.6800000000	0.0133333333
Newton-Trapezoidal	0.6800000000	0.0133333333
Newton-Simpson	0.6666666667	0.0000000000
Gaussian-Legendre	0.6666666667	0.0000000000

程序计算节点-权重  $x_i, A_i$  使用了 `numpy.polynomial` 提供的方法, 更为精确。程序运行结果见日志 `log/q1.log`。

## Exercise 2

当  $X$  的密度函数  $f_X(x)$  与  $q_X(x) = e^{-|x|^3/3}$  成比例时, 试估计  $\sigma^2 = \mathbb{E}(X^2)$ 。

1. 使用带有权重标准化的重要性采样 (Importance Sampling, IS) 估计  $\sigma^2$ 。
2. 使用拒绝抽样 (Rejection Sampling, RS) 估计  $\sigma^2$ 。

**解答 (1)** SIR 估计: 例如选取正态分布  $N(0, b^2)$

$$g(x) = (2\pi b^2)^{-1/2} e^{-x^2/2b^2}$$

因为  $e^{-x^2}$  比  $e^{-|x|^3}$  厚尾, 故这样的  $g$  是符合要求的。步骤如下:

1. 抽取独立同分布样本  $X_1, \dots, X_m \stackrel{\text{i.i.d.}}{\sim} N(0, b^2)$

2. 计算重要性

$$w^*(X_i) = \frac{f(X_i)}{g(X_i)} = \frac{C \cdot q(X_i)}{g(X_i)}$$

其中  $C$  为常数。

3. 标准化重要性

$$w(X_i) = \frac{w^*(X_i)}{\sum_{i=1}^n w^*(X_i)} = \frac{C \cdot q(X_i)/g(X_i)}{\sum_{i=1}^n C \cdot q(X_i)/g(X_i)} = \frac{q(X_i)/g(X_i)}{\sum_{i=1}^n q(X_i)/g(X_i)}$$

4. 从  $X_1, \dots, X_m$  中按照概率  $\{w(X_i)\}_{i=1}^m$  有放回的简单随机抽样, 样本容量为  $n \leq m/10$ , 如此得到  $X_1^*, \dots, X_n^*$ 。这一步不是必须的, 目标若只是估计期望, 则无需重抽样。

5. 计算  $X_i$  的二阶样本原点加权矩作为  $\sigma^2$  的估计

$$\hat{\sigma}^2 = \hat{\mathbb{E}}(h(X)) = \sum_{i=1}^n w(X_i)h(X_i) = \sum_{i=1}^n w(X_i) \cdot X_i^2$$

抽取  $N = 100$  个随机样本，得到估计值为  $\hat{\sigma} = 0.706399$ 。程序结果见文件 `log/q2.log`。

**解答 (2) RS 估计：**注意到  $\log q(x) = -|x|^3/3$ ，当  $x \geq 0$  时  $d^2 \log q/dx^2 = -2x \leq 0$ ；当  $x < 0$  时， $d^2 \log q/dx^2 = 2x < 0$ 。所以由此可知  $q(x)$  是 log-concave 的。

记  $r(x) = \log q(x) = -|x|^3/3$ ，注意到  $r(0) = 0$  且  $r(x)$  是偶函数。不妨用 3 条切线包络，且其中一条为  $l_2(x) = 0$ ，而另 2 条对称。不妨设右切点为  $(x_0, r(x_0))$ ，于是切线为

$$l_1(x) = r'(x_0)(x - x_0) + r(x_0) = -x_0^2 x + \frac{2x_0^3}{3}$$

$$l_2(x) = r'(-x_0)(x + x_0) + r(-x_0) = x_0^2 x + \frac{2x_0^3}{3}$$

其中  $x_0 \geq 0$ 。若设置上下限  $[-N, N]$  希望曲线间面积

$$S_N(x_0) = \int_{-N}^0 \left( x_0^2 x + \frac{2x_0^3}{3} - r(x) \right) dx + \int_0^N \left( -x_0^2 x + \frac{2x_0^3}{3} - r(x) \right) dx$$

$$= \frac{1}{6} N^4 - x_0^2 N^2 + \frac{4}{3} x_0^3 N$$

尽可能小，从而抽样效率更高。解  $\partial S_N(x_0)/\partial x_0 = 0$  得最优切点为  $x_0^* = N/2$ 。于是，我们得到 Envelope 函数

$$e(x) = \begin{cases} \exp\left(-x_0^2 x + \frac{2x_0^3}{3}\right), & x > 2x_0/3 \\ 1, & x \in [-2x_0/3, 2x_0/3] \\ \exp\left(x_0^2 x + \frac{2x_0^3}{3}\right), & x < -2x_0/3 \end{cases}$$




图 2：Target and Envelope Target Function, select  $x_0 = 1.5$ . (left:  $\log q, \log e$ , right:  $q, e$ )

下面构造分布  $g(x) = \alpha \cdot e(x)$  使得  $\int g(x) dx = 1$ ，即

$$\alpha \cdot \left[ \int_{-\infty}^{-2x_0/3} \exp\left(x_0^2 x + \frac{2x_0^3}{3}\right) dx + \frac{4x_0}{3} + \int_{2x_0/3}^{\infty} \exp\left(-x_0^2 x + \frac{2x_0^3}{3}\right) dx \right] = 1$$

求得  $\alpha$  为

$$\alpha = \frac{3x_0^2}{4x_0^3 + 6}$$

为方便从  $g(x)$  中抽取独立同分布样本，下面求  $g(x)$  的概率质量函数，

$$G(x) = \begin{cases} 1 - \frac{\alpha}{x_0^2} \exp\left(-x_0^2 x + \frac{2x_0^3}{3}\right), & x > 2x_0/3 \\ \alpha x + \frac{1}{2}, & x \in [-2x_0/3, +2x_0/3] \\ \frac{\alpha}{x_0^2} \exp\left(x_0^2 x + \frac{2x_0^3}{3}\right), & x < -2x_0/3 \end{cases}$$

不难发现  $G^{-1}(x)$  是容易求得的

$$G^{-1}(u) = \begin{cases} \frac{2x_0}{3} - \frac{1}{x_0^2} \log\left(\frac{x_0^2(1-u)}{\alpha}\right), & u \in [1 - \alpha/x_0^2, 1) \\ \frac{u - 1/2}{\alpha}, & u \in (\alpha/x_0^2, 1 - \alpha/x_0^2) \\ \frac{1}{x_0^2} \log\left(\frac{x_0^2 u}{\alpha}\right) - \frac{2x_0}{3}, & u \in (0, \alpha/x_0^2] \end{cases}$$

下面开始抽样：

1. 抽取独立同分布样本  $U_1, \dots, U_m \stackrel{\text{i.i.d.}}{\sim} U(0, 1)$ 。
2. 计算  $G^{-1}(U_1), \dots, G^{-1}(U_m)$ ，于是有  $X_i = G^{-1}(U_i) \stackrel{\text{i.i.d.}}{\sim} g(X)$ 。
3. 计算  $q(X_i)$  和  $e(X_i)$ 。从  $U(0, 1)$  中抽取独立同分布的  $Z_i$ ，若  $Z_i > q(X_i)/e(X_i)$  则拒绝当前的  $X_i$ 。
4. 如此，接受的  $X_i$  构成  $X_1^*, \dots, X_n^* \stackrel{\text{i.i.d.}}{\sim} f(X)$ ，进而估计  $\sigma^2 = \mathbb{E}(X^2)$

$$\hat{\sigma}^2 = \hat{\mathbb{E}}(X^2) = \frac{1}{n} \sum_{i=1}^n h(X_i^*) = \frac{1}{n} \sum_{i=1}^n [X_i^*]^2$$

使用  $q(X)$  代替  $f(X)$  的原因：若  $f(X) = Cq(X)$ ，则  $f(X)/e(X) = Cq(X)/e(X)$ ，可以将  $e(X)/C$  记为新的  $e(X)$ ，即有等价。

抽取  $N = 100$  个随机样本，取  $x_0 = 1.5$  得到  $\alpha = 0.35$ 。最终估计值为  $\hat{\sigma} = 0.711958$ 。接受率为 82%，其中有 7 个样本阈值  $q(X)/e(X) \geq 1$  占比 7%。程序结果见文件 `log/q2.log`。

### Exercise 3

Let  $z_0 = 0$  and  $z = (z_1, \dots, z_n)$  be a binary sequence (0's and 1's) of Markov chain with, governed by the transition matrix

$$T = \begin{pmatrix} 0.9 & 0.1 \\ 0.05 & 0.95 \end{pmatrix}$$

where  $T_{ij} = \mathbb{P}(z_{t+1} = j | z_t = i)$  is the transition probability. When  $z_t = 1$ , the casino uses a fair die (i.e., each side has equal probability 1/6 to show up); whereas when  $z_t = 0$ , the casino uses a loaded die

that has probability  $1/2$  to show "6", and probability  $1/10$  to show other faces. Of course, we only got to serve the results of the die throws, denoted as the  $y_i$ 's. Note that this is a simple hidden Markov model. Suppose we have observed the results  $\mathbf{y}$  of 100 throws, as

2, 1, 6, 2, 1, 6, 6, 5, 6, 6, 6, 3, 5, 2, 3, 2, 1, 2, 6, 4, 6, 2, 2, 5, 3, 3, 3, 1, 4, 3, 1, 5, 1, 3, 6, 1, 6, 3, 5, 1, 6, 3, 1, 2, 3, 1, 4, 6, 3, 6, 5, 1, 3, 3, 5, 6, 1, 3, 5, 5, 4, 6, 3, 2, 4, 1, 6, 2, 5, 4, 2, 4, 4, 2, 1, 2, 3, 2, 6, 3, 6, 6, 6, 4, 5, 6, 2, 2, 4, 6, 6, 1, 4, 6, 3, 4, 2, 6, 4, 6

1. Sample 10,000 independent draws of  $z$  using the **sequential importance sampling** to estimate  $\mathbb{E}(z|y)$ .
  2. Based on the draws in (a), estimate  $\hat{z} = \arg \max_z \mathbb{P}(z|y)$ . The true underlying hidden sequence is

You can compare your estimated  $\hat{z}$  with the true one.

**解答 (1, 2)** 目标概率分布为  $f(z|y) = f(z_{1:T}|y_{1:T})$ , 其中  $T = n = 100$ 。而转移概率为  $p_z(z_t|z_{t-1}) = T_{z_{t-1}z_t}$ 。给定  $z_t$  后观测的概率为

$$p_y(y_t|z_t) = \begin{cases} 1/6, & z_t = 1 \\ 1/2, & z_t = 0, y_t = 6 \\ 1/10, & z_t = 0, y_t \in \{1, 2, 3, 4, 5\} \end{cases}$$

于是重要性权重为  $w_t(z_{1:t}) \propto w_{t-1}(z_{1:t-1}) \cdot p_y(y_t|z_t)$ 。注意到，观测值  $\mathbf{y}$  已知，下面开始抽取  $N$  个样本：

1. 初始化。设  $z_0 = 0$ , 重要性权重  $w_0 = 1$ 。
  2. 在第  $t$  时刻, 按转移概率  $p_z(z_t|z_{t-1})$  抽样新的分量

$$z_t | z_{t-1} \sim \text{Bernoulli}(1, T_{z_{t-1}1})$$

3. 此时, 由观测值  $y_t$  计算  $p_y(y_t|z_t)$ , 从而更新重要性权重  $w_t(z_{1:t}) \propto w_{t-1}(z_{1:t-1}) \cdot p_y(y_t|z_t)$ 。
  4. 回到第 2 步, 直到达到  $t = T$ 。如此, 得到单个样本序列抽样  $z = z_{1:T}$  和其对应的重要性权重  $w_T(z_{1:T})$ 。
  5. 反复操作  $N$  次 (为提高效率, 也可对上述操作向量化), 得到  $N$  个样本  $z^1, \dots, z^N$  和其权重  $w^1, \dots, w^N$ 。

$z$  的期望可由样本加权和估计，先对权重归一化

$$w_*^i = \frac{w^i}{\sum_{i=1}^N w^i}$$

于是期望的估计值为

$$\hat{\mathbb{E}}(\mathbf{z}|\mathbf{y}) = \frac{1}{N} \sum_{i=1}^N w_*^i \cdot \mathbf{z}^i$$

对于  $\hat{\mathbf{z}} = \arg \max_{\mathbf{z}} \mathbb{P}(\mathbf{z}|\mathbf{y})$ , 即为  $\max w_*^i$  对应的  $\mathbf{z}^i$ 。

结果见程序日志 `log/q3.log`,  $\hat{\mathbf{z}}$  与真实序列  $\mathbf{z}^*$  相差 12 个, 准确率为 88%, 但有效样本量  $\text{ESS} \approx 57$ 。若采用 Particle Filter, 在设置有效样本阈值为  $N/7 \approx 1429$  后, 得到的结果:  $\hat{\mathbf{z}}$  与真实序列  $\mathbf{z}^*$  相差 15 个, 准确率为 85%, 但有效样本量  $\text{ESS} \approx 2562$ 。故采用 Particle Filter 有效样本更大, 其估计  $\hat{\mathbb{E}}(\mathbf{z}|\mathbf{y})$  的方差更小, 下面给出简单地理论证明 (不严格)。




图 3: ESS Plot with Particle Filter

注意到, 在这里有效样本为

$$\text{ESS} = \frac{1}{\sum_{i=1}^N (w_*^i)^2}$$

有效样本 ESS 越大, 归一化重要性权重的平方和  $\sum_{i=1}^N (w_*^i)^2$  越小。设待估计量为  $\boldsymbol{\mu} = \mathbb{E}(\mathbf{z}|\mathbf{y})$ , 由其估计量的形式, 有估计的方差为 (不妨探讨一维情形)

$$\text{Var}[\hat{\boldsymbol{\mu}}] = \frac{1}{N} [\text{Var}(w_*^i \mathbf{z}^i) + \boldsymbol{\mu}^2 \text{Var}(w_*^i)] - 2\boldsymbol{\mu} \text{Cov}(w_*^i \mathbf{z}^i, w_*^i) + O(N^{-2})$$

方差估计为

$$\hat{\text{Var}}[\hat{\boldsymbol{\mu}}] = \frac{1}{N} [S_{w_* \mathbf{z}}^2 + \boldsymbol{\mu}^2 S_{w_*}^2] - 2\boldsymbol{\mu} S_{w_* \mathbf{z}, w_*} + O(N^{-2})$$

注意到  $\bar{w}_* = \sum_{i=1}^N w_*^i / N = 1/N$ , 故有  $w_*^i$  的样本方差

$$S_{w_*}^2 \propto \sum_{i=1}^N (w_*^i)^2 - N(\bar{w}_*)^2 = \sum_{i=1}^N (w_*^i)^2 - \frac{1}{N}$$

而又  $w_*^i \geq 0, \mathbf{z}^i \in \{0, 1\}$ , 于是其他样本方差和协方差

$$S_{w_* \mathbf{z}^i}^2 \propto \sum_{i=1}^N (w_*^i \mathbf{z}^i)^2 - N \bar{w}_* \bar{\mathbf{z}} \leq \sum_{i=1}^N (w_*^i)^2$$

$$S_{w^*z, w_*} \propto = \sum_{i=1}^N (w_*^i z^i) \cdot w_*^i - N \bar{w}_* \bar{w}_* z = \sum_{i=1}^N (w_*^i)^2 z^i - \bar{w}_* z \geq \sum_{i=1}^N (w_*^i)^2 z^i - \bar{w}_* \geq -\frac{1}{N}$$

于是，通过简略的放缩，有

$$\begin{aligned}\hat{\text{Var}}[\hat{\mu}] &\leq \frac{1}{N} \left[ \sum_{i=1}^N (w_*^i)^2 + \mu^2 \left( \sum_{i=1}^N (w_*^i)^2 - \frac{1}{N} \right) \right] + \frac{2\mu}{N} + O(N^{-2}) \\ &= \left( \frac{1}{N} + \mu^2 \right) \sum_{i=1}^N (w_*^i)^2 + \frac{2\mu N - \mu^2}{N^2} + O(N^{-2})\end{aligned}$$

即估计的方差的上界，随  $\sum_{i=1}^N (w_*^i)^2$  减小而减小，而 ESS 越大， $\sum_{i=1}^N (w_*^i)^2$  越小，即估计越有效。

**注** 此处理论证明的放缩不甚严谨，可以采用其他大样本近似的方法推导。

## Exercise 4

1. 拒绝抽样 (Rejection Sampling, RS) 与抽样重要性重抽样 (Sampling Importance Resampling, SIR) 都是常用的抽样方法，但 RS 是精确方法 SIR 却是近似方法。解释 SIR 是近似方法的原因。
2. 重要性采样 (Importance Sampling, IS) 与抽样重要性重抽样 (Sampling Importance Resampling, SIR) 听起来非常相似，但它们服务于不同的目的。请对比这两种方法：
  - (a). 它们各自的主要目标是什么？
  - (b). 比较两种方法估计均值  $\mu$  的方差，IS 的方差更小，从直观上解释这一现象。
  - (c). 如果使用拒绝抽样 (Rejection Sampling, RS) 估计均值  $\mu$ ，其方差与 IS 估计的方差相比如何？是否有确定的答案？
3. 随着维度增加，许多经典采样方法的效率急剧下降（维度诅咒）。例如，拒绝抽样的接受率会指数级下降。结合深度学习的发展，是否有新的思路来解决高维采样问题？

**解答 (1)** SIR 第一步从已知分布抽样，而非目标分布，故只能近似。而在第二步重采样，又一次引入随机性。若第一步样本量不足，从而有第二步重采样不准确。整体而言，就是近似的方法。（相比于 SIR，被 RS 接受的样本，确实是落在了目标分布中）。

**解答 (2)** IS 关注与对积分/期望的估计，无需真正的产生服从目标分布的样本，产生的样本是不等权的，通过加权进行后续的估计。SIR 目标是产生近似服从目标分布的样本，这些样本是等权的，可以作为目标分布的样本进行后续的操作。

SIR 在重抽样阶段又一次引入了随机性，故方差更大。

RS 在选取的已知分布对目标分布包络良好、接受率高时，产生的样本更加近似服从目标分布，估计的方差小。IS 方法估计的方差同样取决于已知分布的选取，即对权重的计算有所不同，会导致不同的方差。故没有确定的答案，需要针对特定的选取考虑

**解答(3)** 例如，直接训练一个网络，使其拟合已有的样本。训练完成后，传入一个随机初始值，得到一个新的样本。

$$f(\mathbf{Y}; \boldsymbol{\theta}_{\text{NN}}) \sim \mathbf{X} \Rightarrow \hat{\mathbf{X}} = f(\mathbf{Y}_0; \boldsymbol{\theta}_{\text{NN}}), \quad \mathbf{Y}, \mathbf{Y}_0 \text{ are r.v.}$$

其中  $\mathbf{X}$  是观测到的目标族（高维）， $\mathbf{Y}, \mathbf{Y}_0$  作为辅助变量（低维），服从已知的一个分布。

再如，训练循环神经网络 GNN，在已有观测数据上训练。然后抽样低维  $\mathbf{X}_{0:b}$ ，对后续进行预测，得到新的高维样本

$$f_{\text{GNN}}(\mathbf{X}_0; \boldsymbol{\theta}_{\text{NN}}) = \mathbf{X} \Rightarrow \hat{\mathbf{X}} = f_{\text{GNN}}(\hat{\mathbf{X}}_0; \boldsymbol{\theta}_{\text{NN}})$$

当然，也可以考虑双向 GNN。如此输入即可为中间分量  $\mathbf{X}_{a:b}$  的数据。

或者，直接将高维  $\mathbf{X}$  视作序列，除了上述的 GNN，还可以使用其他 Seq2Seq 模型，甚至是 Transformer 架构。产生新的样本，只需输入低维的数据，然后由网络进行预测。

当然，如上方法均未验证。考虑到网络可能存在黑盒性，且后续的估计很难写出解析式，故相关统计性质比较难评估。